

Documentação Seminário

Descrição dos algoritmos utilizados

RSA

- É um algoritmo de encriptação assimétrica, ou seja, utiliza uma chave pública e uma chave privada para o processo de encriptação/decriptação
- O texto em claro e o cifrado s\u00e3o inteiros entre 0 e n 1, para algum n (geralmente 1024 bits)
 - o O texto em claro é encriptado em blocos, onde cada um tem um valor binário menor que n
- Encriptação
 - $\circ \ C = M^e \bmod n$
 - C = Texto encriptado
 - M = Mensagem em claro
 - e = Expoente público
 - o n = Módulo público
- Decriptação
 - $\circ \ M = C^d \bmod n$
 - C = Texto encriptado
 - M = Mensagem em claro
 - d = Expoente privado
 - o n = Módulo público
- Para o cálculo dos valores acima (n, e, d) deve-se seguir os seguintes passos
 - o Gerar dois números grandes primos (p e q)
 - $\circ~$ Calcular o produto n=p imes q
 - $\circ~$ Calcular o produto $\phi(n)=(p-1) imes (q-1)$
 - $\circ~$ A partir desses valores, deve ser escolhido um valor "e" tal que "e" seja coprimo com $\phi(n)$ e $1 < e < \phi(n)$
 - $\circ~$ A partir disso, o valor de d é calculado da seguinte forma $d \equiv e^{-1} mod n$
- Segurança do algoritmo
 - A segurança desses cálculos foi comprovada matematicamente e se baseia na dificuldade de fatorar números grandes compostos
 - O cálculo dos valores mencionados deve ser "trivial" para quem possui todas as informações, no entanto o cálculo inverso deve ser computacionalmente inviável (por meio de logaritmo discreto)

OAEP - Optimal Asymetric Encryption Padding

- O OAEP transforma uma mensagem em claro antes dela ser cifrada. Evitando que ela fique pequena ou com padrões previsíveis, garantindo que um mesmo texto produza textos cifrados diferentes e deixando o processo mais seguro
- Funcionamento do algoritmo
 - o Divisão do bloco
 - A mensagem vira um bloco de dados (db) e uma seed. O bloco de dados é composto por um padding (ps) de bytes de 0x00, um delimitador 0x01 e a mensagem original
 - Geração de máscara (mfg1)

- Produz uma máscara para o bloco de dados a partir da seed
- Produz uma máscara para a seed a partir do bloco de dados
- Aplicação das máscaras
 - Através de um XOR as respectivas máscaras são aplicadas
- Combinação de blocos
 - Os resultados são combinados, ficando um byte inicial 0x00, o seed mascarado e o bloco de dados mascarado
- Segurança
 - A seed torna os textos cifrados imprevisíveis
 - O padding e a máscara removem padrões previsíveis na mensagem
 - A segurança depende da resistência à colião de hash

SHA-3 - Secure Hash Alorithm 3

- Uma função de hash produz uma saída de tamanho fixo e é determinística, ou seja, a mesma entrada gera sempre o mesmo hash
- Além disso, ela possui resistência a colisões, dessa forma é díficil encontrar duas entradas diferentes que gerem o mesmo hash
- Além desas características, o SHA-3 possui uma característica especial: uma construção matemática chamada função esponja
 - Os blocos da entrada são combinados gradativamente → Absorção
 - Ao processar a entrada por completo, o hash final é gerado em partes → Escoamento
- Algoritmo
 - O estado inicial é uma matriz de 5×5 onde cada posição armazena 64 bits
 - A entrada então é dividida em blocos de acordo com a taxa (r). No caso do algoritmo usado no trabalho (sha3_256)
 r = 1088 bits
 - Então cada bloco é combinado com a matriz através de operaões XOR e depois o estado é modificado pela função de permutação Keccak-f
 - Theta: adiciona redundância a cada coluna da matriz
 - Rho: rotaciona bits em cada posição da matriz
 - Pi: rearranja as posições dentro da matriz
 - Chi: Introuz não linearidade (aplicação de XOR entre bits da matriz)
 - lota: adiciona uma constante evitando a simetria entre rodadas
 - Depois de processar todos os blocos, o estado interno gera o hash final, r bits de cada vez
- Segurança
 - Função Esponja: resiste contra ataques como colisões e pré-imagens
 - Alta entropia: combinando operações bit a bit e constantes específicas eliminam padrões
 - Adaptável a diferentes tamanhos de entrada e saída
 - Imune a ataques que explora a dependência entre blocos

Análise da implementação

Geração de chaves

```
def miller_rabin(n, d):
    a = randint(2, n - 2)
    x = pow(a, d, n)
```

```
if x == 1 or x == n - 1:
        return True
    while d != n - 1:
        x = pow(x, 2, n)
        d *= 2
        if x == 1:
            return False
        if x == n - 1:
            return True
    return False
def isprime(n, k=5):
    if n == 2:
        return True
    if n < 2 or n % 2 == 0:
        return False
    d = n - 1
    while d % 2 == 0:
        d //= 2
   for _ in range(k):
        if not miller_rabin(n, d):
            return False
    return True
def gen_prime():
    while True:
        min_bits = 2 ** (NUM_BITS - 1)
        max\_bits = 2 ** NUM\_BITS - 1
        prime_number = randprime(min_bits, max_bits)
        if isprime(prime_number):
            return prime_number
def gcd(a, b):
    while b != 0:
        a, b = b, a \% b
    return a
def mod_inverse(a, m):
    m0, y, x = m, 0, 1
   if m == 1:
        return 0
    while a > 1:
        q = a // m
        m, a = a \% m, m
        y, x = x - q * y, y
```

```
return x + m0 if x < 0 else x

def generate_keys():
    p = gen_prime()
    q = gen_prime()
    n = p * q
    phi = (p - 1) * (q - 1)
    e = 65537

while gcd(e, phi) != 1:
    e = randrange(2, phi)

d = mod_inverse(e, phi)

return (e, n), (d, n)</pre>
```

- Para a geração dos números primos "p" e "q" foi utilizada uma função da biblioteca sympy chamada randprime
 - $\circ~$ A função retorna um valor primo entre os valores passados no parâmetro. No caso, o valor deve estar entre 2^{1023} e $2^{1024}-1$
- Escolha de "e"
 - Ao chamar a função gcd, checamos se "e" e "phi" são coprimos ao utilizar o Algoritmo de Euclides (princíoio de que o MDC não muda se o menor número for subtraído do maior
 - \circ Caso esses números não sejam coprimos, um número aleatório entre 2 e $\phi(n)$ é selecionado até que essa propriedade seja verdadeira
- Checagem de primalidade
 - o Para checar se o númeor gerado é primo, foi utilizado o teste de primalidade de Miller-Rabin

Criptografia / Decriptografia

```
def xor_bytes(a, b):
    return bytes([i ^ j for i, j in zip(a, b)])
def mgf1(seed, mask_len):
    hlen = sha3_256().digest_size
    output = b""
    for i in range(0, -(-mask_len // hlen)):
        c = i.to_bytes(4, 'big')
        output += sha3_256(seed + c).digest()
    return output[:mask_len]
def oaep_encode(message, n):
    mlen = len(message)
    pad = b' \times 00' * (n - mlen - PADDING_LENGTH // 8 - 2)
    db = pad + b' \times 01' + message
    seed = getrandbits(SEED_LENGTH).to_bytes(SEED_LENGTH // 8, 'big')
    db_mask = mgf1(seed, len(db))
    masked_db = xor_bytes(db, db_mask)
```

```
seed_mask = mgf1(masked_db, SEED_LENGTH // 8)
   masked_seed = xor_bytes(seed, seed_mask)
   return b'\x00' + masked seed + masked db
def rsa_encrypt(plaintext, public_key):
   e, n = public_key
   k = (n.bit_length() + 7) // 8
   encoded_message = oaep_encode(plaintext, k)
   plaintext_int = int.from_bytes(encoded_message, 'big')
   ciphertext = pow(plaintext_int, e, n)
   return ciphertext
def oaep_decode(encoded_message, k):
   encoded_message = encoded_message[1:]
   masked_seed = encoded_message[:SEED_LENGTH // 8]
   masked_db = encoded_message[SEED_LENGTH // 8:]
   seed_mask = mgf1(masked_db, SEED_LENGTH // 8)
   seed = xor_bytes(masked_seed, seed_mask)
   db_mask = mgf1(seed, len(masked_db))
   db = xor_bytes(masked_db, db_mask)
   lhash_len = len(sha3_256().digest())
   ps_{end} = db.index(b'\x01', lhash_len)
   message = db[ps\_end + 1:]
   return message
def rsa_decrypt(ciphertext, private_key):
   d, n = private_key
   k = (n.bit_length() + 7) // 8
   plaintext_int = pow(ciphertext, d, n)
   plaintext = plaintext_int.to_bytes(k, 'big')
   return oaep_decode(plaintext, k)
```

- Antes da encriptação ser feita, o texto é passado pela função de OAEP
 - O OAEP primeiro aplicará um padding de b'\x00' e no final colocar b'\x01' indicando que a mensagem vem logo após
 - Após isso, é gerado uma seed aleatória que será usada na função mfg1. Nela é criada uma máscara para o bloco de dados (db) e então é aplicada a partir de uma função XOR bit a bit
 - A partir do bloco de dados mascarado, é feita uma máscara para a seed, a qual é aplicada por meio de um XOR bit a bit também
- Após esse processo, a cifra RSA é aplicada em cima da mensagem encodificada
- O processo inverso é simples, ao aplicar a decifração do RSA, é chamada a funão de remoção do padding
 - Essa função remove o primeiro byte (b'\x00')
 - Divide a mensagem em seed mascarada e bloco de dados mascarado

Documentação Seminário

5

- o Desmascara a seed a partir da função mfg1 e da máscara do bloco de dados
- o Desmascara o bloco de dados a partir da função mfg1 e da seed
- Após isso, encontra o byte b'\x01' e separa a mensagem verdadeira do preenchimento

Assinatura Digital

```
def calculate_hash(file_path):
    with open(file_path, 'rb') as f:
        while chunk := f.read(4096):
            sha3_256().update(chunk)

return sha3_256().digest()

def sign_file(file_path, private_key):
    hash = calculate_hash(file_path)
    signature = rsa_encrypt(hash, private_key)
    formatted_signature = b64encode(signature.to_bytes((signature.bit_length() + 7) // 8, 'big')
    return formatted_signature

def verify_file(file_path, base64_signature, public_key):
    signature = int.from_bytes(b64decode(base64_signature), 'big')
    decrypted_hash = rsa_decrypt(signature, public_key)
    current_hash = calculate_hash(file_path)
    return decrypted_hash == current_hash
```

- Para a parte final, primeiro é lido o arquivo de blocos em blocos e é calculado o hash
 - Como foi comentado anteriormente, o sha3 é um algoritmo esponja, ou seja, aplica o hash a cada bloco para depois retornar o hash final. A analogia é feita como se fosse uma esponja acumulando água para depois soltar
 - Logo depois é feita uma assinatura digital. Isso é feito ao criptografar o hash calculado anteriormente. A partir dele
 e da chave privada do usuário é feito todo o processo comentado anteriormente na criptação. O resultado então é
 convertido para base64 para facilitar o armazenamento e o envio. Dessa forma, o resultado da criptografia, que é
 um númeor muito grande, é transformado um uma string legível
- A verificação da assinatura é feita com base no hash, no arquivo enviado e na chave pública
 - A assinatura recebida é decodificada (transformada de base64 para um número)
 - Esse valor é decriptografado utilizando a chave pública daquele que enviou o hash
 - o O hash é calculado novamente com base no documento enviado
 - Se forem iguais, o documento é válido
 - Se forem diferentes, o documento pode ter sido alterado, tornando-o inválido

Algumas considerações

Como cada processo contribui para o aumento da segurnaça?

- O algoritmo RSA, como foi comentado anteriormente, tem sua segurnaça baseada na dificuldade de fatoração de números muito grandes. A partir da chave pública, foi matematicamente comprovado ser computacionalmente inviável realizar o processo inverso (logaritmo discreto) para descobrir a chave privada
- O OAEP adiciona mais uma camada de "aleatoriedade na mensagem". Ao adicionar um padding, uma seed e mascarar a seed e o bloco de dados como um todo, o processo retira padrões que podem existir em mensagens e ainda altera o tamanho da mensagem a ser enviada. Dessa forma, fica ainda mais inviável reocnhecer padrões da mensagem codificada

- Sem contar que dessa forma uma mesma mensagem pode gerar saídas diferentes
- Já o SHA3 tem uma proteção contra colisões muito eficiente, ou seja, é difícil encontrar duas mensagens que resultem no mesmo hash. Além disso, ele garante a integridade de um documento, dessa forma qualquer alteração que seja feita gera hashes completamente diferentes no resultado final
 - Curiosidade: a função esponja do SHA3-256 protege a mensagem contra atques de comprimento. A forma de funcionamento do SHA2, por exemplo, possibilitava que o atacante utilizasse a estrutura interna do hash após o processamento da mensagem para calcular outros hashes válidos. Por causa d aforma de absorção do SHA3 (como uma esponja), ele deixa de depender de um estado interno exposto

Por que o valor de "e" escolhido foi 65537?

- Esse é um valor comumente usado para um valor inicial "e"
- Caso ele não seja satisfeito, deve ser escolhido outro valor que satisfaça as condições de ser coprimo com $\phi(n)$ e estar entre 2 e $\phi(n)$

Quais são as vulnerabilidades do algoritmo implementado?

- Troca de chaves
 - Ao interceptar uma troca de chaves entre emissor e receptor, ele pode substituir as chaves públicas com chaves falsas, fazendo com que ambos criptografem mensagens com as chaves erradas
 - Solução: Uso de um Certificado Digital autenticado por uma Autoridade Certififcadora para validar a chave pública
- · Ataque antes da assinatura
 - Ao modificar uma mensagem antes da sua assinatura, o atacante ainda consegue causar danos à integridade da informação
 - Solução: Uso do timestamp, ou seja, última modificação do arquivo
- · Man in the middle
 - Um agacante pode tentar alterar a integridade da informação durante o processo de comunicação
 - Solução: Para evitar isso, basta verificar se o hash calculado corresponde à assinatura recebida

O tamanho da mensagem importa?

- Para o RSA puro, a mensagem deve ser menor que o tamanho do módulo
 - \circ Ou seja, M < n; onde M é a mensagem e "n" o módulo (calculado por meio de $p \times q$)
 - O OAEP tem um grande impacto nisso, visto que ele reduz o espaço para a mensagem. Epsar dele aumentar a segurança significativamente, o seu preenchimento diminui a quantidade de informações que podem ser repassadas
 - Solução: Divisão da mensagem em blocos ou uso do esquema híbrido, com o uso de criptografia simétrica e assimétrica
- Na assinatura digital, o tamanho da mensagem também importa
 - Para isso, é possível utilizar funções de hashes compactos, como é o caso do SHA-256, reduzindo o tamanho do hash

O quão complexo é o algoritmo em questão de tempo?

- Geração de chaves
 - O processo consiste na feração de primos de 1024 bits e testá-los por meio do Teste da Primalidade de Miller-Rabin
 - Miller-Rabin tem uma complexidade de $O(k \log 2n)$, onde k é a precisão do algoritmo/número de iterações
 - Esse processo pode ser demorado na fase de teste de primalidade e na fase de escolha de "e", visto que caso o número inicial não tenha as propriedades corretas, deve ser escolhido outro aleatoriamente entre um intervalo muito grande
 - o Para núemeros de 2048 e 4096 bits, esse tempo pode ser ainda maior

- Encriptação/Decriptação
 - Como o valor de "e" geralemente é significativamente menor, a criptografia é mais rápida
 - o O processo inverso geralemente tem uma velocidade mais lenta, dado o tamanho de "d"
- Cálculo do hash
 - o A função SHA3-256 possui uma complexidade linear onde N é o tamanho da entrada
 - o Para arquivos muito grandes, ele pode levar mais tempo, mas no geral é considerado um algoritmo veloz

Fontes

- Geração de primos aletórios: https://www.geeksforgeeks.org/how-to-generate-large-prime-numbers-for-rsa-algorithm/
- Biblioteca de hash: https://docs.python.org/3/library/hashlib.html
- OAEP: https://docs.python.org/3/library/hashlib.html
- RSA-OAEP: https://gist.github.com/ppoffice/e10e0a418d5dafdd5efe9495e962d3d2
- Miller test: https://www.geeksforgeeks.org/primality-test-set-3-miller-rabin/

Documentação Seminário

8